

Inteligência Artificial

Modelos Não-Paramétricos

Prof. Fabio Augusto Faria

1º semestre 2021



Tópicos

- O que são modelos Paramétricos e Não-Paramétricos?
- Modelo k Vizinhos mais próximos (kNN)
- Máquina de Vetores Suporte (SVM)

Modelos Paramétricos

- **Modelos Paramétricos:**

- Formal: São aqueles que conseguem descrever, por meio de **parâmetros/pesos**, um conjunto de exemplos de treinamento amostrados de uma distribuição;
- Informal: modelo que **descarta** o conjunto de treinamento após etapa de treino, i.e., “resume” uma distribuição;

- **Exemplos:**


- Árvores de Decisão → criação da topologia da árvore;
- Redes Neurais Artificiais → conjunto de pesos das arestas
- Redes Convolucionais → filtros da rede

Modelos Não-Paramétricos

- São aqueles modelos que utilizam de parte ou inteiro conjunto de treinamento para prever uma classe ou estimar valores contínuos dos exemplos de teste.
- **Exemplo:**
 - KNN
 - SVM

k Nearest Neighbour (kNN)


- **Classificação ($y = \text{valor discreto}$)**



- **Escolhe-se previamente um valor para k ;**
- **Adota-se uma função de distância** (e.g., Manhattan ou Euclidiana)

k Nearest Neighbour (kNN)


- **Classificação ($y = \text{valor discreto}$)**



- **Escolhe-se previamente um valor para k ;**
- **Adota-se uma função de distância** (e.g., Manhattan ou Euclidiana)

k Nearest Neighbour (kNN)

- Classificação ($y = \text{valor discreto}$)



Classe final é definida pela votação majoritária entre os k vizinhos;




= 1



= 2

k Nearest Neighbour (kNN)


- **Regressão (y = valor contínuo)**



- **Escolhe-se previamente um valor para k ;**
- **Adota-se uma função de distância** (e.g., Manhattan ou Euclidiana)

k Nearest Neighbour (kNN)


- **Regressão (y = valor contínuo)**



- **Escolhe-se previamente um valor para k ;**
- **Adota-se uma função de distância** (e.g., Manhattan ou Euclidiana)

k Nearest Neighbour (kNN)

- **Regressão (y = valor contínuo)**



Valor final (y) pode ser definido como a média aritmética entre os k vizinhos;


k Nearest Neighbour (kNN)

- Desafio é achar o valor de **k** e **distância** que melhor se ajuste aos dados de treinamento;
- Utiliza-se validação cruzada para encontrar os melhores parâmetros k.

k Nearest Neighbour (kNN)


$K = 1$

Training data



error = 0.0

Testing data




error = 0.15

k Nearest Neighbour (kNN)


$K = 3$

Training data



error = 0.0760

Testing data




error = 0.1340

k Nearest Neighbour (kNN)


$K = 7$

Training data



error = 0.1320

Testing data




error = 0.1110

k Nearest Neighbour (kNN)


K = 21

Training data



error = 0.1120

Testing data




error = 0.0920

Máquina de Vetores Suporte (SVM)

- A técnica de aprendizagem (classificação e regressão) mais importante da literatura criada por Vapnik (1995);
- Na dúvida de qual técnica utilizar, SVM com certeza será uma boa solução;
- Desafio está na definição da classe dos exemplos na **fronteira de decisão ou área de risco**;

$$f(\mathbf{x}) = \mathbf{w}^\top \mathbf{x} + b$$

2D
Achar uma Reta




Máquina de Vetores Suporte (SVM)


- A técnica de aprendizagem (classificação e regressão) mais importante da literatura;
- Na dúvida de qual técnica utilizar, SVM com certeza será uma boa solução;
- Desafio está na definição da classe dos exemplos na **fronteira de decisão ou área de risco**;

$$f(\mathbf{x}) = \mathbf{w}^\top \mathbf{x} + b$$


3D
Achar um Plano



Máquina de Vetores Suporte (SVM)



(a) Classificador Linear




(b) SVM

Máquina de Vetores Suporte (SVM)

- Contrói um separador de **margem máxima**, o qual ajuda na generalização;
- Cria um **hiperplano de separação linear** por meio da projeção de um espaço de mais alta dimensionalidade (kernel trick);
- SVM é uma técnica não-paramétrico, pois **seleciona** alguns poucos **exemplos de treinamento** para suportar o hiperplano.
- Combina vantagens dos não-paramétricos e paramétricos com flexibilidade para representar funções complexas e resistente à overfitting.

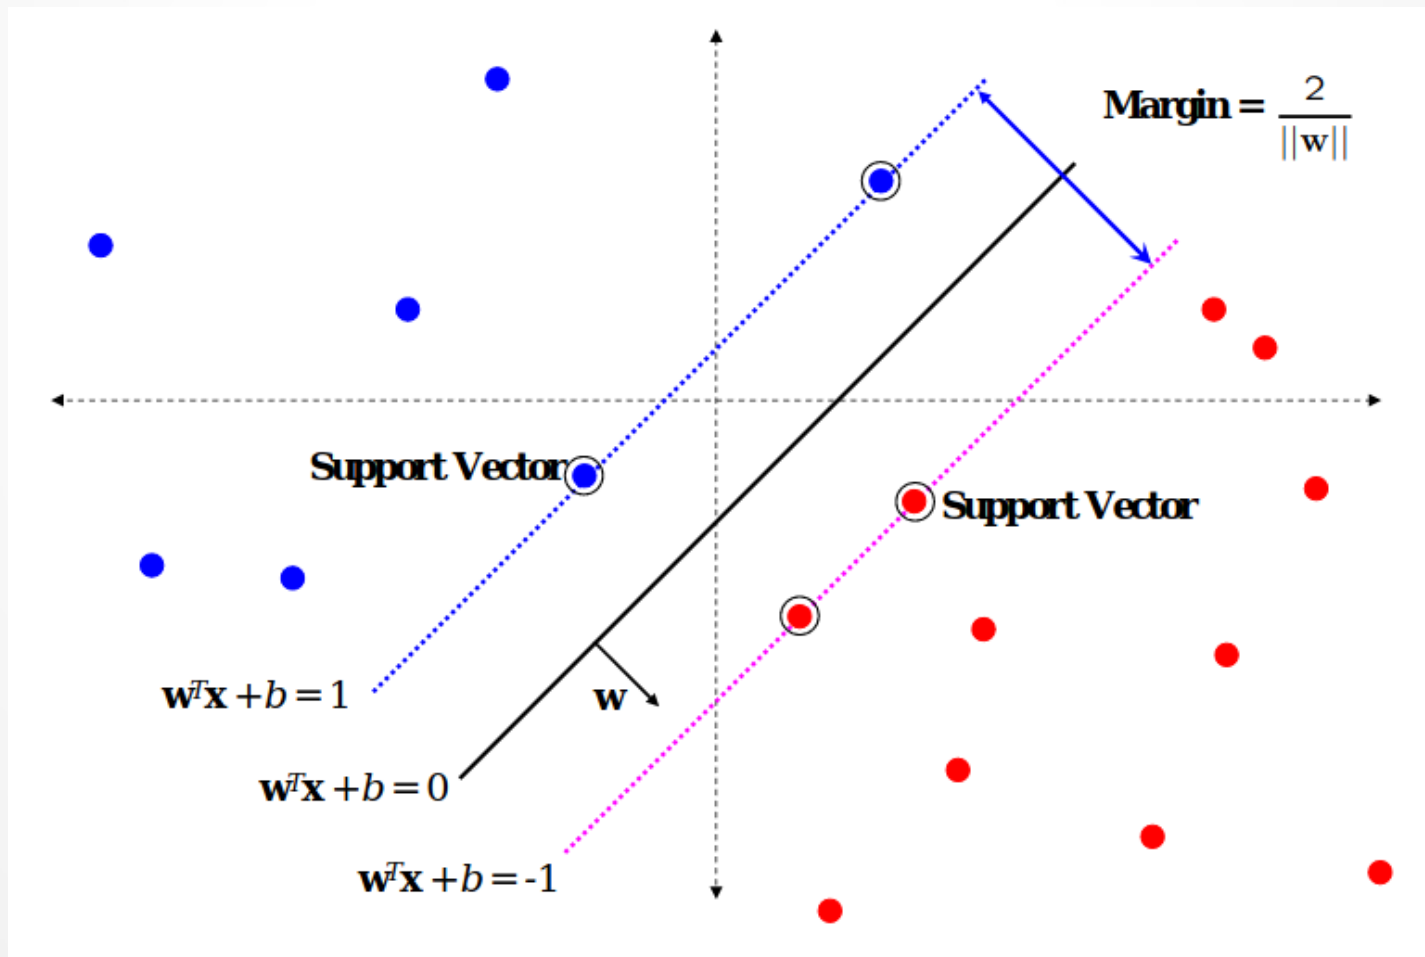
Máquina de Vetores Suporte (SVM)

- Como funciona?



Máquina de Vetores Suporte (SVM)

- A margem é definida como:
$$\frac{\mathbf{w}^\top (\mathbf{x}_+ - \mathbf{x}_-)}{\|\mathbf{w}\|} = \frac{2}{\|\mathbf{w}\|}$$



Máquina de Vetores Suporte (SVM)

- **Desafio do algoritmo de otimização:**

$$\max_{\mathbf{w}} \frac{2}{\|\mathbf{w}\|} \text{ subject to } \mathbf{w}^\top \mathbf{x}_i + b \begin{cases} \geq 1 & \text{if } y_i = +1 \\ \leq -1 & \text{if } y_i = -1 \end{cases} \text{ for } i = 1 \dots N$$

- **Equivalente na otimização Quadrática:**

$$\min_{\mathbf{w}} \|\mathbf{w}\|^2 \text{ subject to } y_i (\mathbf{w}^\top \mathbf{x}_i + b) \geq 1 \text{ for } i = 1 \dots N$$

Máquina de Vetores Suporte (SVM)

- **Desafio do algoritmo de otimização:**


$$\max_{\mathbf{w}} \frac{2}{\|\mathbf{w}\|} \text{ subject to } \mathbf{w}^\top \mathbf{x}_i + b \begin{cases} \geq 1 & \text{if } y_i = +1 \\ \leq -1 & \text{if } y_i = -1 \end{cases} \text{ for } i = 1 \dots N$$

- **Equivalente na otimização Quadrática:**

$$\min_{\mathbf{w}} \|\mathbf{w}\|^2 \text{ subject to } y_i (\mathbf{w}^\top \mathbf{x}_i + b) \geq 1 \text{ for } i = 1 \dots N$$


Máquina de Vetores Suporte (SVM)

- Mas o Mundo real?



Máquina de Vetores Suporte (SVM)

- Otimização por Margem Suave ou “Soft Margin”:



Máquina de Vetores Suporte (SVM)

- Novo algoritmo de otimização:

$$\min_{\mathbf{w} \in \mathbb{R}^d, \xi_i \in \mathbb{R}^+} ||\mathbf{w}'||^2 + C \sum_i^N \xi_i$$


- Sujeito à:

$$y_i (\mathbf{w}' \mathbf{x}_i + b) \geq 1 - \xi_i \text{ for } i = 1 \dots N$$

- **C é o parâmetro de regularização:**
 - C **pequeno** significa aceitar exemplos do lado errado → margem larga (large)
 - C **grande** é baixa tolerância de exemplos do lado errado → margem estreita (narrow)
 - C infinito sem tolerância de exemplos errados → margem difícil (Hard)


Máquina de Vetores Suporte (SVM)

- **Parâmetro C: Hard Margin**



Máquina de Vetores Suporte (SVM)

- **Parâmetro C: Soft Margin**




Máquina de Vetores Suporte (SVM)

- **Teoremas e conceitos que regem a técnica SVM:**
 - **Cover**: Todo conjunto de amostras não-linearmente separáveis, no espaço de característica original, ao serem projetados para mais alta dimensionalidade, existe alta probabilidade de se tornarem linearmente separáveis;
 - **Mercer** (1909): qualquer função de kernel “razoável” corresponde para algum espaço de característica;
 - ***Kernel Trick***: uso de uma função de kernel para projetar os dados do espaço original para um novo espaço definido pela função adotada.

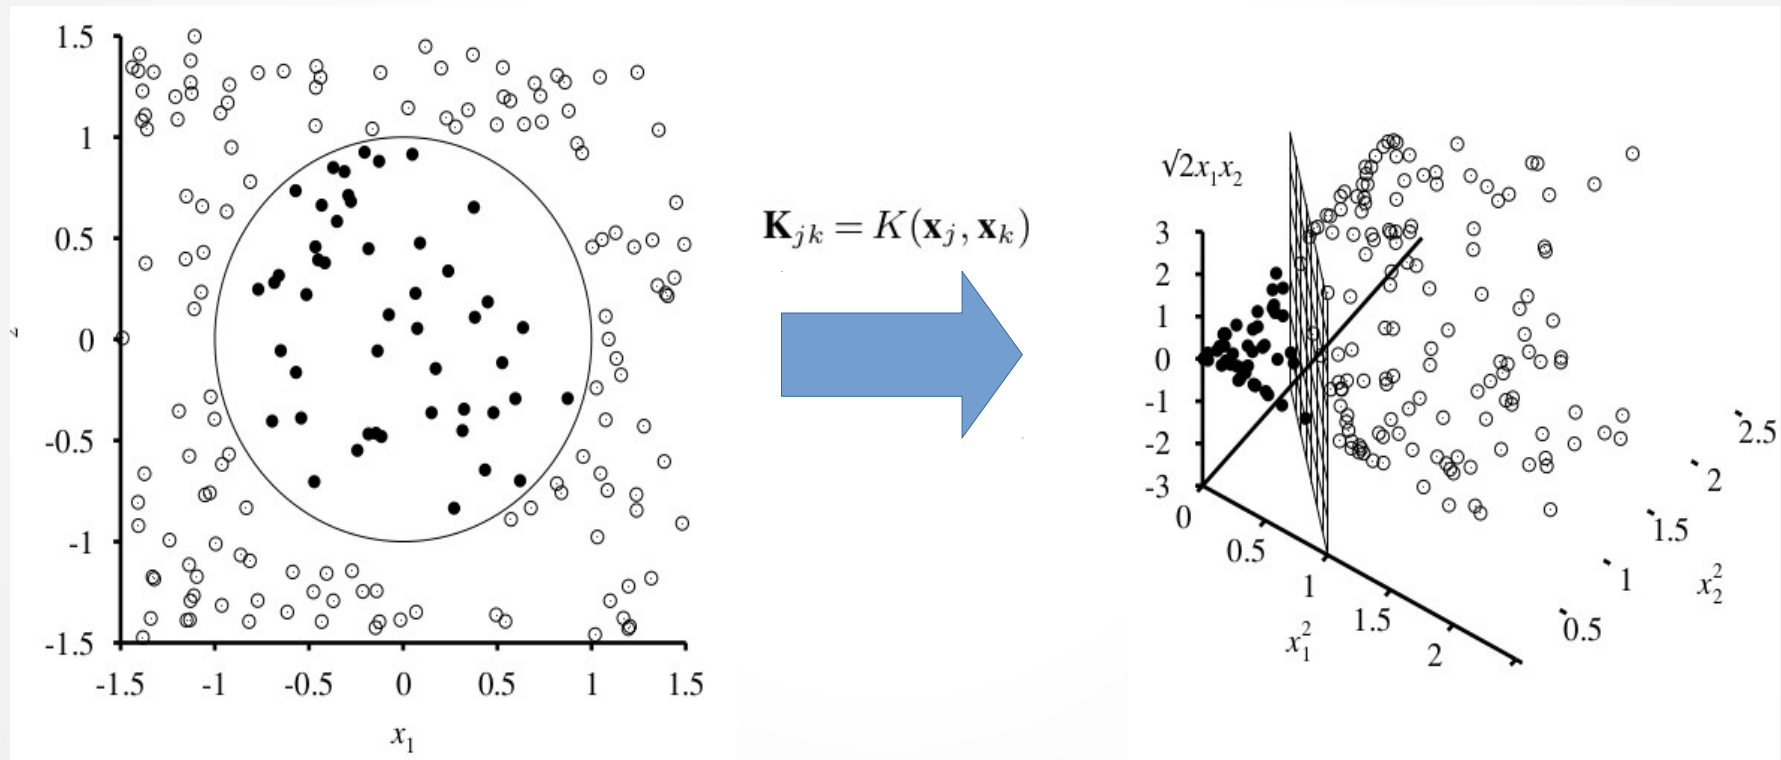
Máquina de Vetores Suporte (SVM)

- **Kernel Trick:**



Máquina de Vetores Suporte (SVM)

- Kernel Trick:**




Máquina de Vetores Suporte (SVM)

- Tipos de funções de Kernel:

Tipo de Kernel	Função $\mathcal{K}(\mathbf{x}_i, \mathbf{x}_j)$	Tipo do Classificador
Polinomial	$(\langle \mathbf{x}_i \cdot \mathbf{x}_j \rangle + 1)^p$	Máquina de aprendizagem polinomial
Gaussiano (ou RBF)	$\exp\left(-\frac{\ \mathbf{x}_i - \mathbf{x}_j\ ^2}{2\sigma^2}\right)$	Rede RBF
Sigmoidal	$\tanh(\beta_0 \langle \mathbf{x}_i \cdot \mathbf{x}_j \rangle) + \beta_1$	Perceptron de duas camadas

Máquina de Vetores Suporte (SVM)

- **Funções de Kernel utilizando IRIS Dataset no sk-Learn:**



Exercícios para 02/06/2021

- 1) Fazer o mesmo experimento da lista anterior, mas agora utilizando KNN e SVM para classificação e regressão;
- 2) Plotar gráfico comparativo entre kNN com diferentes $k=\{1,3,5\}$ e distâncias (Manhattan e Euclidiana);
- 3) Plotar gráfico comparativo entre as diferentes funções de kernel para SVM e explicar o que observou;
- 4) Rodar um algoritmo de busca pelos melhores parâmetros chamado GRIDSEARCH para a função de kernel RBF e comparar o resultado final (melhorou ou piorou?) com aqueles obtidos pelos parâmetros “default”.
 - https://scikit-learn.org/stable/auto_examples/model_selection/plot_grid_search_digits.html

DIVIRTA-SE!!!!

Referências

- Peter Norvig e Stuart Russel. **Inteligência Artificial**. Cap. 18. Seção 8 e 9.
- Slides de Andrew Zisserman (University of Oxford)
- <http://www.recod.ic.unicamp.br/~fabiof/ia1s2019/class12/class12.pdf>
- http://www.recod.ic.unicamp.br/~fabiof/ia1s2019/class12/svm_classes12.pdf
- Scikit-Learn
 - KNN <https://scikit-learn.org/stable/modules/neighbors.html>
 - SVM <https://scikit-learn.org/stable/modules/svm.html>